

UNIVERSIDAD CENTRAL DE VENEZUELA
FACULTAD DE CIENCIAS, ESCUELA DE MATEMÁTICAS
CÁTEDRA: ESTADÍSTICA



**INFORME TÉCNICO: PROYECTO 1 ESTADÍSTICA DESCRIPTIVA,
INFERENCIA ESTADÍSTICA Y SIMULACIÓN COMPUTACIONAL**

Profesor: Prof. Manuel Solórzano

Autor: Danny Delgado

C.I. de identidad: 29.698.333

Correo electrónico: delgadodanny101@gmail.com

Caracas, julio de 2026

INDICE GENERAL.

PORTADA	i
1. INTRODUCCION	1
2. EJERCICIO 1: ESTADISTICA DESCRIPTIVA Y VIZUALIZACION DE DATOS	2
2.1. Parte I: Estadística Descriptiva (Medidas por Estación y por Mes)	2
2.2. Parte II: Representación Gráfica (Boxplot, Barras y Tallo-Hoja)	3
2.3. Parte III: Interpretación de Resultados y Variabilidad Térmica	4
3. EJERCICIO 2: INTERVALO DE CONFIANZA PARA LA MEDIA POBLACIONAL	6
3.1. Construcción del Intervalo al 95% y 99%	6
3.2. Interpretación y Comparación de Amplitudes	6
4. EJERCICIO 3: INTERVALO DE CONFIANZA PARA UNA PROPORCIÓN	7
4.1. Estimación de la Proporción Poblacional de Uso de IA	7
4.2. Validación de Hipótesis mediante el Intervalo	7
5. EJERCICIO 4: COTA DE CRAMÉR–RAO	8
5.1. Análisis Teórico y Simulación de Monte Carlo ($M = 10\,000$, $n = 30$)	8
5.2. Evaluación de la Eficiencia del Estimador	8
6. EJERCICIO 5: TEOREMA DE RAO–BLACKWELL	9
6.1. Simulación y Reducción de la Varianza Muestral	10
6.2. Conclusión sobre la Suficiencia y Eficiencia	10
7. EJERCICIO 6: SIMULACIÓN Y ESTIMACIÓN POR MÁXIMA VEROSIMILITUD	11
7.1. Método de Transformación Inversa y Generación de Datos	12
7.2. Evaluación del Teorema Central del Límite y Probabilidad Empírica	13
8. CONCLUSIONES GENERALES	14
9. REFERENCIAS BIBLIOGRÁFICAS	15
10. ANEXOS: SCRIPTS DE PYTHON	16

1. INTRODUCCIÓN.

La estadística constituye una rama fundamental del saber científico que actúa como puente indispensable entre los modelos matemáticos abstractos y la interpretación de los fenómenos reales. Su aplicación metodológica permite recopilar, procesar, analizar y generalizar información empírica, facilitando la toma de decisiones fundamentada bajo condiciones de incertidumbre. En el ámbito de las ciencias exactas y aplicadas, el análisis riguroso de los datos no solo se limita a describir las características particulares de un grupo observado mediante coeficientes de tendencia central y dispersión, sino que trasciende hacia la inferencia estadística, permitiendo modelar el comportamiento poblacional a partir de muestras representativas.

El presente informe técnico recoge el desarrollo integral de la Tarea Práctica del curso, abarcando una amplia gama de metodologías estadísticas que comprenden desde la **estadística descriptiva univariada y la visualización gráfica de datos meteorológicos**, hasta la **construcción de intervalos de confianza** para medias y proporciones poblacionales. Asimismo, se profundiza en los fundamentos teóricos de la inferencia mediante el estudio riguroso de propiedades de los estimadores a través de la **cota de Cramér–Rao**, el **Teorema de Rao–Blackwell** y los métodos de **simulación de Monte Carlo** aplicados a la estimación por máxima verosimilitud.

Para cumplir con los objetivos analíticos y algorítmicos planteados, la ejecución de los experimentos y la validación de las distribuciones teóricas se han implementado mediante el desarrollo de scripts computacionales en **Python**. Adicionalmente, para potenciar la presentación de los resultados, el proyecto incorpora el uso de **Streamlit**, un framework interactivo de código abierto cuyo objetivo principal es transformar los modelos numéricos y estadísticos en aplicaciones web dinámicas. Mediante esta herramienta, se logra renderizar de forma limpia, visual y en tiempo real las métricas, las tablas analíticas y los gráficos con temas personalizados, sirviendo como un entorno interactivo óptimo para la demostración y validación de los modelos teóricos expuestos en este estudio.

2. EJERCICIO 1: ESTADISTICA DESCRIPTIVA Y VIZUALIZACION DE DATOS.

Parte 1.1.

Parte 1.1

	Estado	Estacion	Ene	Feb	Mar	Abr	May	Jun	Jul	Ago	Sep	Oct	Nov	Dic	Media_aritmetica	Mediana	Varianza
0	AL	Mobile	40	42.7	50.1	57.1	64.4	70.7	73.2	72.9	68.7	57.3	49.1	43.1	57.4417	57.2	
1	AK	Juneau	19	22.7	26.7	32.1	38.9	45	48.1	47.3	42.9	37.2	27.2	22.6	34.1417	34.65	
2	AZ	Phoenix	41.2	44.7	48.8	55.3	63.9	72.9	81	79.2	72.8	60.8	48.9	41.8	59.275	58.05	
3	AR	LittleRock	29.1	33.2	42.2	50.7	59	67.4	71.5	69.8	63.5	50.9	41.5	33.1	50.9917	50.8	
4	CA	LosAngeles	47.8	49.3	50.5	52.8	56.3	59.5	62.8	64.2	63.2	59.2	52.8	47.9	55.525	54.55	
5	CA	Sacramento	37.7	41.4	43.2	45.5	50.3	55.3	58.1	58	55.7	50.4	43.4	37.8	48.0667	47.9	
6	CA	SanDiego	48.9	50.7	52.8	55.6	59.1	61.9	65.7	67.3	65.6	60.9	53.9	48.8	57.6	57.35	
7	CA	SanFrancisco	41.8	45	45.8	47.2	49.7	52.6	53.9	55	55.2	51.8	47.1	42.7	48.9833	48.45	
8	CO	Denver	16.1	20.2	25.8	34.5	43.6	52.4	58.6	56.9	47.6	36.4	25.4	17.4	36.2417	35.45	
9	CT	Hartford	15.8	18.6	28.1	37.5	47.6	56.9	62.2	60.4	51.8	40.7	32.8	21.3	39.475	39.1	

Tabla 1. Distribución de datos limpios del archivo temperatura.txt

Parte 1.2.

Parte 1.2

	Media_aritmetica	Mediana	Varianza_muestral	Desviacion_estandar_muestral	Valor_minimo	Valor_maximo	Rango
Ene	25.7771	21.6	249.1577	15.7847	-2.2	65.6	67.8
Feb	29.0314	25.1	225.0028	15.0001	2.8	65.4	62.6
Mar	36.7029	33.6	153.8144	12.4022	15.3	67.2	51.9
Abr	44.7171	43.8	100.2073	10.0104	28.4	68.7	40.3
May	52.9714	52.2	73.4556	8.5706	38.4	72.1	33.7
Jun	60.6143	61.2	61.9742	7.8724	45	75.1	30.1
Jul	65.02	65.7	55.9822	7.4821	48.1	81	32.9
Ago	63.9943	64.2	56.1741	7.4949	47.3	79.2	31.9
Sep	57.8486	56.9	77.4908	8.8029	42.9	75.9	33
Oct	48.0286	45.9	94.3597	9.7139	35.1	72.3	37.2

Tabla 2. Medidas de tendencia central aplicadas a los meses del archivo temperatura.txt

Los datos reflejan una variabilidad térmica estacional marcada. Por ejemplo, en enero, la desviación estándar es de **15.78 °F** (indicando una alta diferencia entre estaciones), mientras que en julio esta se reduce a **7.48 °F**, lo que sugiere que las temperaturas son relativamente más homogéneas entre las distintas estaciones durante los meses de verano.

Parte 2.1.




Gráfico 1. Grafico Boxplot de la variable *PromAnual* del dataframe *temperaturas.txt*

El diagrama de caja de la variable **PromAnual** presenta una asimetría positiva (sesgo a la derecha). Esto se evidencia tanto por un coeficiente de asimetría de 0.518 como por la ubicación de la mediana dentro de la caja, la cual se encuentra desplazada hacia los valores inferiores, mientras que el bigote y la caja superior se extienden más hacia temperaturas elevadas. Esto sugiere que existen algunas estaciones con temperaturas promedio anuales notablemente más altas que arrastran la media hacia la derecha, alejándola del centro de la distribución.

Parte 2.2.




Gráfico 2. Gráfico de barras comparando los promedios anuales de las temperaturas en cada una de las ciudades registradas en el dataframe *temperatura.txt*

Parte 2.3.




Gráfico 3. Diagrama de tallo y hojas con las temperaturas asociadas

La distribución de las temperaturas promedio anuales es mayoritariamente **unimodal** y presenta un ligero sesgo positivo (hacia temperaturas más altas). La mayoría de los datos se encuentran en el rango de los **30 °F** a los **50 °F**, con una disminución gradual hacia las temperaturas más extremas (tanto frías como cálidas).

Se observa un agrupamiento principal en la rama de los 40 °F, que contiene la mayor cantidad de estaciones. Un segundo grupo significativo se encuentra en la rama de los 30 °F, lo que sugiere que gran parte de las estaciones meteorológicas analizadas operan en un clima templado-frío.

Los datos muestran una alta concentración entre los 30 °F y los 50 °F. Por el contrario, los valores en las ramas de los **60 °F** y **70 °F** son escasos, representando casos particulares de estaciones con temperaturas promedio anuales superiores a la mayoría del conjunto.

Parte 3.1.

Al comparar la media (**46.11 °F**) con la mediana, se observa una proximidad que sugiere una distribución relativamente simétrica, aunque se recomienda verificar visualmente con el histograma para confirmar si existe un leve sesgo.

Parte 3.2.

$$Q_1 = 39.30 ; Q_3 = 51.65$$

$$RIC = Q_3 - Q_1 = 12.35$$

$$\text{Límite inferior: } Q_1 - 1.5 * RIC = 20.77$$

$$\text{Límite superior: } Q_3 + 1.5 * RIC = 70.18$$

Utilizando el criterio de Tukey, se establecieron los límites inferior y superior para identificar valores atípicos. El límite inferior calculado es **20.77 °F** y el límite superior es **70.18 °F**.

Al aplicar estos límites a la variable **PromAnual**, no se identificaron valores atípicos en el conjunto de datos, ya que todas las observaciones se encuentran dentro del rango delimitado. Por lo tanto, se puede afirmar que la distribución de las temperaturas promedio anuales es consistente y no

presenta estaciones con valores climáticos extremos que distorsionen significativamente el comportamiento del conjunto analizado.

Parte 3.3.

Con una desviación estándar de **10.11 °F** respecto a una media de **46.11 °F**, la variabilidad se considera moderada-alta, lo que demuestra diferencias climáticas significativas entre las estaciones analizadas.

Parte 3.4.

La estación con mayor temperatura promedio anual es Honolulu.

Parte 3.5.

La estación con menor temperatura promedio anual es Duluth.

Parte 3.6.

A partir del análisis descriptivo de las temperaturas, se concluye que las estaciones meteorológicas evaluadas presentan un comportamiento térmico heterogéneo a lo largo del año. Esta variabilidad queda de manifiesto al observar que las medidas de dispersión mensual, tales como la desviación estándar que alcanza valores significativos de hasta 15.78 °F en los meses de invierno, evidencian diferencias marcadas entre las distintas regiones geográficas. Si bien todas las estaciones siguen un ciclo estacional común, la magnitud de la fluctuación térmica entre el mes más cálido y el más frío varía sustancialmente de una estación a otra, demostrando que no existe un patrón climático uniforme en el conjunto de datos estudiado, sino una diversidad de regímenes térmicos que responden a las particularidades climáticas de cada ubicación.

Parte 3.7.

La estación meteorológica con la mayor variabilidad térmica anual es Minneapolis. Esta estación presenta la fluctuación de temperatura más extrema del conjunto de datos analizado. La combinación de un rango elevado **60.3 °F** y una desviación estándar mensual considerable **21.13 °F** confirma que Minneapolis experimenta variaciones térmicas drásticas entre las distintas épocas del año, lo cual es indicativo de un clima continental con veranos calurosos e inviernos muy fríos, situándola como la estación con mayor variabilidad térmica anual en comparación con el resto de las localizaciones estudiadas.

3. EJERCICIO 2: INTERVALO DE CONFIANZA PARA LA MEDIA POBLACIONAL.

Parte 1.1.

Código para calcular el intervalo de confianza

```
import scipy.stats as stats
import numpy as np

# Datos
n = 64
x_bar = 42
sigma = 8

# funcion para calcular el intervalo de confianza
def CalcularIntervalo(confianza, n, x_bar, sigma):
    alpha = 1 - confianza
    z = stats.norm.ppf(1 - alpha / 2)
    error = z * (sigma / np.sqrt(n))
    return (x_bar - error, x_bar + error)
```

Código 1. Función CalcularIntervalo ubicada en math_utils.py

La función imita la siguiente formula.

$$\bar{x} = Z_{\alpha/2} * \frac{\sigma}{\sqrt{n}}$$

Existe un nivel de confianza del 95% de que el verdadero tiempo medio poblacional de entrega de los pedidos de la empresa se encuentra comprendido entre **40.04 y 43.96** minutos. Esto significa que, si repitiéramos el muestreo muchas veces, el 95% de los intervalos calculados contendrían el verdadero tiempo promedio de entrega.

Al aumentar el nivel de confianza al **99%**, el valor crítico Z aumenta (pasa de **1.96** a aproximadamente **2.58**). Esto provoca que el margen de error también aumente, siendo el intervalo **39.42 y 44.58** minutos el correspondiente con el **99%** de confianza.

El intervalo al **99%** es más estrecho que el del **95%**. Esto es consistente con la teoría estadística: para tener una mayor certeza (99% frente al **95%**) de que el parámetro poblacional se encuentra dentro de nuestro intervalo, necesitamos abarcar un rango de valores mayor, sacrificando precisión por una mayor seguridad.

4. EJERCICIO 3: INTERVALO DE CONFIANZA PARA UNA PROPORCIÓN.

Parte 1.1

Código para calcular el intervalo de confianza

```
import scipy.stats as stats
import numpy as np

# Datos
n = 400
 exitos = 280
 confianza = 0.95

# Proporción muestral
p_hat = exitos / n

# Intervalo de confianza
z = stats.norm.ppf(1 - (1 - confianza) / 2)
error = z * np.sqrt((p_hat * (1 - p_hat)) / n)
intervalo = (p_hat - error, p_hat + error)
```

Código 2. Función *CaclarIntervaloProporcion* ubicada en *math_utils.py*

El código mostrado imita la siguiente fórmula.

$$\bar{p} \mp Z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Tenemos una proporción poblacional de **0.70 (70.00%)** y un nivel de confianza del **95%** de que la verdadera proporción poblacional de estudiantes que utilizan herramientas de inteligencia artificial está contenida en el intervalo de **0.6551 a 0.7449**.

Dado que todo el intervalo de confianza **[0.6551, 0.7449]** se encuentra por encima del valor **0.60** (60%), existe evidencia estadística suficiente, con un nivel de confianza del **95%**, para concluir que la proporción de estudiantes que utilizan herramientas de inteligencia artificial es mayor al **60%**.

5. EJERCICIO 4: COTA DE CRAMÉR–RAO.

Parte 1.1

El código mostrado determina la simulación establecida.

```
Codigo para calcular el sesgo y la varianza empírica

import numpy as np

# Configuración inicial del experimento
np.random.seed(42) # Para reproducibilidad
theta = 4.0
p = 1.0 / theta
n = 30
M = 10000

# 1. Simulación de M = 10,000 muestras de tamaño n = 30 de una distribución geomét
# Nota: np.random.geometric usa p como parámetro de éxito.
muestras = np.random.geometric(p=p, size=(M, n))

# 2. Calcular la media muestral X_bar para cada una de las M muestras
x_bar = np.mean(muestras, axis=1)
theta_hat = x_bar

# 3. Estimar el sesgo de theta_hat
esperanza_estimador = np.mean(theta_hat)
sesgo = esperanza_estimador - theta

# 4. Calcular la varianza empírica del estimador
varianza_empirica = np.var(theta_hat, ddof=1)

# 5. Calcular el límite teórico de Cramér-Rao: [theta * (theta - 1)] / n
cramer_rao_bound = (theta * (theta - 1)) / n
```

Código 3. Código para calcular el sesgo y la varianza empírica

Consideramos una variable aleatoria X con distribución geométrica cuyo parámetro es $p = \frac{1}{\theta}$. Para esta distribución, la esperanza matemática es:

$$E(X) = \frac{1}{p} = \theta$$

Por lo tanto, la media muestral $\bar{X}$ es un estimador insesgado de θ , ya que $E(\bar{X}) = \theta$.

El sesgo de un estimador $\hat{\theta} = \bar{X}$ se define como:

$$\text{Sesgo}(\hat{\theta}) = E(\hat{\theta}) - \theta$$

Dado que $\hat{\theta}$ es insesgado teóricamente, el sesgo esperado es **0**. En los resultados de la simulación con $M = 10000$ muestras, el sesgo empírico obtenido es un valor sumamente pequeño cercano a 0.0036, lo cual confirma de forma empírica la propiedad de insesgado del estimador.

Varianza empírica obtenida en la simulación ≈ 0.4079

Límite inferior de Cramér–Rao teórico:

$$\text{LCR} = \frac{\theta(\theta - 1)}{n} = \frac{4(4 - 1)}{30} = \frac{12}{30} = 0.40$$

Como la varianza empírica del estimador (≈ 0.4079) es prácticamente igual al límite inferior de Cramér–Rao (0.40), se concluye que la media muestral $\bar{X}$ es un estimador eficiente (o alcanza la cota de eficiencia de Cramér–Rao) para el parámetro θ de la distribución geométrica bajo las condiciones del tamaño de muestra evaluado.

6. EJERCICIO 5: TEOREMA DE RAO–BLACKWELL.

Parte 1.1:

Código en Python para la Simulación ↗

```
import numpy as np
import pandas as pd
import streamlit as st

# Configuración inicial del experimento
np.random.seed(42)
theta = 4.0
p = 1.0 / theta
n = 20
M = 10000

# 1. Generar M = 10,000 muestras de tamaño n = 20 de una distribución geométrica
muestras = np.random.geometric(p=p, size=(M, n))

# 2. Estimador inicial: X_1 (primer elemento de cada muestra)
theta_1 = muestras[:, 0]

# 3. Estadístico suficiente U = suma de los elementos de cada muestra
U = np.sum(muestras, axis=1)

# 4. Estimador mejorado por Rao-Blackwell: E(X_1 | U) = U / n = X_bar
theta_star = U / n

# 5. Cálculo de las varianzas empíricas
var_theta_1 = np.var(theta_1, ddof=1)
var_theta_star = np.var(theta_star, ddof=1)
reduccion_porcentual = ((var_theta_1 - var_theta_star) / var_theta_1) * 100
```

Código 4. Función *SimularTeoremaRaoBlackwell* ubicada en *math_utils.py*

Considere la distribución geométrica con función de probabilidad:

$$f(x; \theta) = \frac{1}{\theta} \left(1 - \frac{1}{\theta}\right)^{x-1}, \quad x = 1, 2, 3,$$

Considere los siguientes estimadores:

Estimador inicial: $\widehat{\theta}_1 = X_1$.

Estadístico suficiente: $U = \sum_{i=1}^n X_i$.

Estimador mejorado $\widehat{\theta}^* = E(X_1 | U) = \frac{U}{n} = \bar{X}$

Este teorema establece que si se tiene un estimador insesgado para un parámetro y se le condiciona respecto a un estadístico suficiente (U), el nuevo estimador resultante no solo sigue siendo insesgado, sino que garantiza una varianza menor o igual que la del estimador original ($\text{Var}(\widehat{\theta}^*) \leq \text{Var}(\widehat{\theta}_1)$).

El estimador inicial $\widehat{\theta}_1 = X_1$ utiliza únicamente la primera observación de la muestra, desperdiciando la información del resto de los datos, lo que genera una dispersión (varianza) muy alta.

Al aplicar la esperanza condicional dado el estadístico suficiente $U = \sum X_i$, se obtiene la media muestral $\bar{X}$, la cual aprovecha toda la información contenida en la muestra.

Dando como resultado los siguientes datos.

	Estimador Evaluado	Varianza Empírica Obtenida	Descripción y Eficiencia
0	Estimador Inicial	11.9141	Alta dispersión al basarse en una sola observación de la muestra.
1	Estimador Mejorado (Rao–Blackwell)	0.5956	Varianza drásticamente reducida (Reducción del 95.00%) al condicionar sobre el estadístico suficiente.

La simulación demuestra de manera contundente que la varianza empírica de la media muestral ($\text{Var}(\bar{X}) \approx 0.5956$) es significativamente menor que la varianza del estimador inicial ($\text{Var}(X_1) \approx 11.9141$). Esto representa una reducción de la varianza del 95%, comprobando empíricamente el Teorema de Rao–Blackwell.

7. EJERCICIO 6: SIMULACIÓN Y ESTIMACIÓN POR MÁXIMA VEROSIMILITUD.

Parte 1.1:

Código para la simulación y estimación

```
import numpy as np
import pandas as pd

# Parámetros del experimento
np.random.seed(42)
n = 100
theta_real = 2.0
M = 5000

# 1. Generación de datos mediante transformación inversa
#  $X = U^{1/(1+\theta)}$ 
U = np.random.uniform(0, 1, size=(M, n))
X = U ** (1.0 / (1.0 + theta_real))

# 2. Cálculo del Estimador de Máxima Verosimilitud (EMV) para cada una de las M mu
#  $\theta_{hat\_mv} = -n / \sum(\ln(X_i)) - 1$ 
suma_ln_x = np.sum(np.log(X), axis=1)
theta_mv = -n / suma_ln_x - 1.0

# 3. Estudio del punto 3: Probabilidad empírica de que  $|X\_bar - E[X]| > 0.5$ 
E_X = (theta_real + 1.0) / (theta_real + 2.0) # Debería ser 0.75 para theta = 2
x_bar_muestras = np.mean(X, axis=1)
desviaciones = np.abs(x_bar_muestras - E_X)
probabilidad_empirica = np.mean(desviaciones > 0.5)
```

Código 5. Función SimularMaximaVerosimilitud ubicada en math_utils.py

Teniendo en cuenta la siguiente densidad:

$$f(x; \theta) = (1 + \theta)x^\theta, \quad 0 \leq x \leq 1, \quad \theta > -1$$

Se utilizará el método de transformación inversa para generar observaciones de esta distribución. Si $U \sim \text{Uniform}(0,1)$, entonces $X = U^{\frac{1}{1+\theta}}$.

Consideremos $n = 100$ y $\theta = 2$. Genere una muestra aleatoria de tamaño n .

Utilizando el estimador:

$$\widehat{\theta}_{MV} = -\frac{n}{\sum_{i=1}^n \ln(X_i)} - 1$$

Resultados Numéricos Clave

Media Empírica ($\hat{\theta}_{MV}$)

2.0340

Esperanza Teórica $\mathbb{E}[X]$

0.7500

Probabilidad Empírica

0.0000

Desviación estándar empírica de los EMV: 0.3057

Distribución Empírica del Estimador de Máxima Verosimilitud




Gráfico 4. Distribución empírica del Estimador de Máxima Verosimilitud ($\hat{\theta}_{MV}$) obtenida mediante simulación de Monte Carlo ($M=5000$ repeticiones, tamaño de muestra $n=100$)

El método de transformación inversa permite generar datos aleatorios de una distribución continua a partir de una variable uniforme $U(0,1)$ igualando la función de distribución acumulada ($F(x)$) a U . Para esta función de densidad, al integrar se obtiene $F(x) = x^{\theta+1}$, y despejando X se llega a la expresión de generación $X = U^{\frac{1}{1+\theta}}$.

De acuerdo con la teoría de Inferencia Estadística y el Teorema Central del Límite (TCL), los Estimadores de Máxima Verosimilitud poseen propiedades deseables en muestras grandes ($n = 100$), tales como ser asintóticamente insesgados y asintóticamente normales. Por lo tanto, la

distribución empírica de $\widehat{\theta}_{MV}$ tras $M = 5\,000$ simulaciones tiende a adoptar una forma acampanada de tipo normal en torno al valor verdadero $\theta = 2$.

Al evaluar el comportamiento de la media muestral $\bar{X}$ frente a su valor esperado teórico ($E[X] = 0.75$), el cálculo de la probabilidad empírica arroja qué tan frecuentes son las desviaciones extremas mayores a 0.5 en las muestras simuladas.

8. CONCLUSIONES GENERALES.


El desarrollo integral de este proyecto ha permitido consolidar la vinculación entre los fundamentos teóricos de la estadística descriptiva, la teoría de estimación y los métodos de simulación computacional, evidenciando las siguientes conclusiones fundamentales:

1. **Heterogeneidad Térmica y Comportamiento Climático:** El análisis descriptivo de las temperaturas medias mensuales en las estaciones meteorológicas de los Estados Unidos demostró la existencia de un comportamiento térmico heterogéneo a lo largo del año. Estaciones de carácter continental como *Minneapolis* exhiben una fluctuación extrema, con rangos de temperatura y desviaciones estándar significativamente superiores en comparación con el conjunto de datos analizado, reflejando regímenes climáticos marcados por veranos cálidos e inviernos rigurosos.
2. **Inferencia Poblacional y Precisión Muestral:** Mediante la construcción de intervalos de confianza, se comprobó que tanto la estimación del tiempo medio de entrega como la proporción de estudiantes que utilizan herramientas de inteligencia artificial brindan un alto grado de certeza estadística. Los resultados confirmaron que, al incrementar el nivel de confianza (del 95% al 99%), los intervalos se expanden de manera proporcional, reflejando el principio metodológico de intercambiar precisión por una mayor seguridad en la cobertura del parámetro poblacional. Asimismo, los intervalos permitieron validar de forma concluyente hipótesis específicas sobre las proporciones de uso tecnológico en el ámbito universitario.
3. **Eficiencia de Estimadores y Cota de Cramér–Rao:** A través de la simulación de Monte Carlo aplicada a modelos geométricos, se comprobó empíricamente que la media muestral ($\bar{X}$) actúa como un estimador insesgado de θ . Al comparar la varianza empírica del estimador con el límite inferior de Cramér–Rao, los resultados numéricos demostraron que dicho estimador **alcanza la cota de eficiencia**, validando su optimalidad estadística bajo las condiciones de tamaño muestral evaluadas.
4. **Optimización por el Teorema de Rao–Blackwell:** La experimentación computacional aplicada al Teorema de Rao–Blackwell evidenció una reducción drástica de la varianza empírica (superior al 95%) al transicionar desde un estimador inicial basado en una sola observación (X_1) hacia un estimador condicionado respecto al estadístico suficiente ($\bar{X}$). Esto confirma en la práctica que el acondicionamiento algebraico elimina la variabilidad espuria y maximiza el aprovechamiento de la información muestral.
5. **Propiedades Asintóticas y Máxima Verosimilitud:** Finalmente, la simulación de muestras grandes ($n = 100$) bajo distribuciones regidas por el método de máxima verosimilitud confirmó las propiedades asintóticas de los estimadores. La distribución empírica de los estimadores $\widehat{\theta}_{MV}$ converge de forma clara hacia una aproximación normal, respaldada teóricamente por el Teorema Central del Límite, lo que corrobora la robustez de los modelos probabilísticos implementados mediante scripts en Python para la resolución de problemas de inferencia avanzada.

9. REFERENCIAS BIBLIOGRÁFICAS.

- Hernández Chaudary, J. B. (2026). *Tema 1: Estadística Descriptiva*. Escuela de Matemáticas, Facultad de Ciencias, Universidad Central de Venezuela (UCV).
- Hernández Chaudary, J. B. (2026). *Tema 2: Inferencia Estadística*. Escuela de Matemáticas, Facultad de Ciencias, Universidad Central de Venezuela (UCV).
- Olivares M., M. M. (2004). *Estadística Descriptiva: Apuntes de Cátedra*. Universidad Central de Venezuela (UCV).
- Casella, G., & Berger, R. L. (2002). *Statistical Inference* (2ª ed.). Duxbury Press. (Texto fundamental de referencia para propiedades de estimadores, Cota de Cramér–Rao y Teorema de Rao–Blackwell).
- McKinney, W. (2022). *Python for Data Analysis: Data Wrangling with Pandas, NumPy, and Jupyter* (3ª ed.). O'Reilly Media. (Referencia para la implementación de algoritmos de simulación y procesamiento numérico).
- Hogg, R. V., McKean, J. W., & Craig, A. T. (2019). *Introduction to Mathematical Statistics* (8ª ed.). Pearson.

10. ANEXOS: SCRIPTS DE PYTHON.



Función: CalcularMediasDescriptivasEstacion ubicado en math_utils.py

```
def CalcularMedidasDescriptivasEstacion(df):  
  
    df = df.drop('PromAnual', axis=1) #quitar la columna de  
    promedio  
  
    df_aux = pd.DataFrame()  
  
    # axis=1 aplica la operacion a lo largo de una fila  
    df_aux['Media_aritmetica'] =  
df.select_dtypes(include=['number']).mean(axis=1)  
    df_aux['Mediana'] =  
df.select_dtypes(include=['number']).median(axis=1)  
    df_aux['Varianza_muestral'] =  
df.select_dtypes(include=['number']).var(axis=1)  
    df_aux['Desviacion_estandar_muestral'] =  
df.select_dtypes(include=['number']).std(axis=1)  
    df_aux['Valor_minimo'] =  
df.select_dtypes(include=['number']).min(axis=1)  
    df_aux['Valor_maximo'] =  
df.select_dtypes(include=['number']).max(axis=1)  
    df_aux['Rango'] = df_aux['Valor_maximo'] -  
df_aux['Valor_minimo']  
  
    df_final = pd.concat([df, df_aux], axis=1) # coloca las  
nuevas columnas al lado del df original  
  
    return df_final
```

Función: CalcularIntervalo ubicado en math_utils.py

```
def CalcularIntervalo(confianza, n, x_bar, sigma):  
    alpha = 1 - confianza  
    z = stats.norm.ppf(1 - alpha / 2)  
    error = z * (sigma / np.sqrt(n))  
    return (x_bar - error, x_bar + error)
```

Función: GenerarTalloHojas ubicado en math_utils.py

```
def GenerarTalloHojas(datos):

    datos = sorted(datos)
    tallo_hojas = {}

    for num in datos:
        tallo = num // 10
        hoja = num % 10
        if tallo not in tallo_hojas:
            tallo_hojas[tallo] = []
        tallo_hojas[tallo].append(str(hoja))

    resultado = "Tallo | Hojas\n"
    resultado += "-----\n"
    for tallo in sorted(tallo_hojas.keys()):
        resultado += f"{tallo:5} | {'
'.join(tallo_hojas[tallo])}\n"
    return resultado
```

Función: CalcularMedidasDescriptivasMes ubicado en math_utils.py

```
def CalcularMedidasDescriptivasMes(df):

    df = df.drop('PromAnual', axis=1) #quitar la columna de
    promedio

    df_aux = pd.DataFrame()

    # axis=1 aplica la operacion a lo largo de una columna
    df_aux['Media_aritmetica'] =
df.select_dtypes(include=['number']).mean(axis=0)
    df_aux['Mediana'] =
df.select_dtypes(include=['number']).median(axis=0)
    df_aux['Varianza_muestral'] =
df.select_dtypes(include=['number']).var(axis=0)
    df_aux['Desviacion_estandar_muestral'] =
df.select_dtypes(include=['number']).std(axis=0)
    df_aux['Valor_minimo'] =
df.select_dtypes(include=['number']).min(axis=0)
    df_aux['Valor_maximo'] =
df.select_dtypes(include=['number']).max(axis=0)
    df_aux['Rango'] = df_aux['Valor_maximo'] -
df_aux['Valor_minimo']

    return df_aux
```